Evidencias del workflow de Machine Learning

Predicción de riesgo de bajo desempeño en Saber 11 — Grupo 3

Salidas reales de los comandos del proyecto, ejecutados sobre el periodo 20224 de Bogotá. Cada resultado se reproduce con los comandos de la sección 10 del README.

1. Adquisición de datos

Descarga desde la API de datos.gov.co. Al repetir el comando, la ingesta no descarga de nuevo (idempotencia):

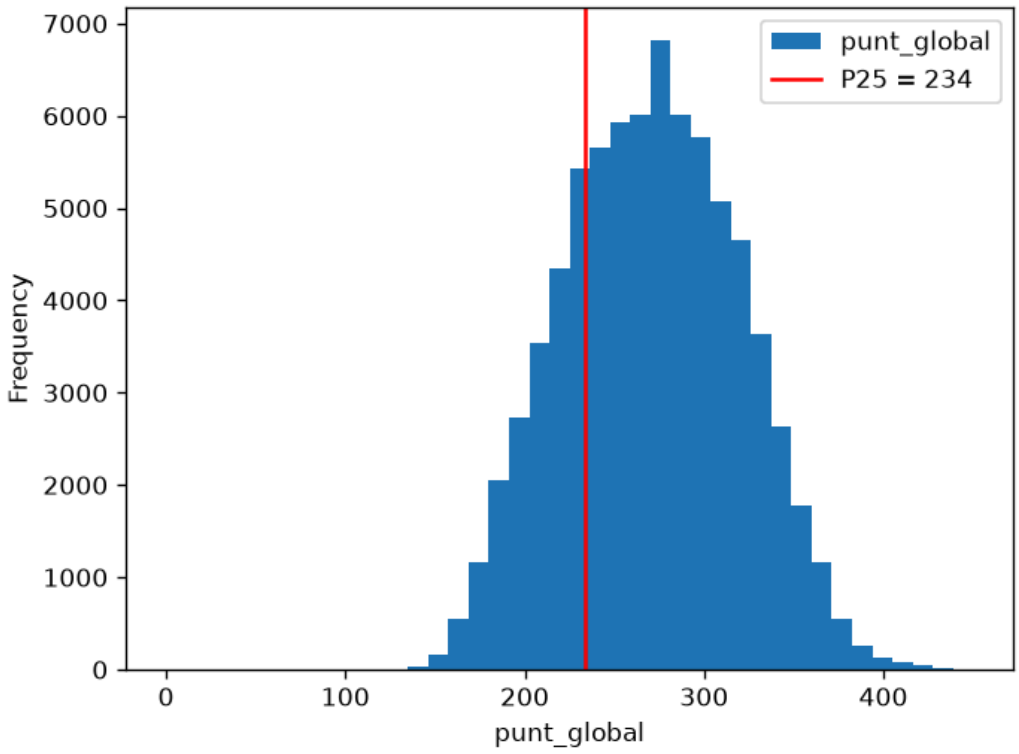
```
data/raw/saber11.csv ya existe; no se descarga de nuevo (usa --force para repetir).
```

Carga en SQLite ejecutada dos veces. El número de filas no cambia:

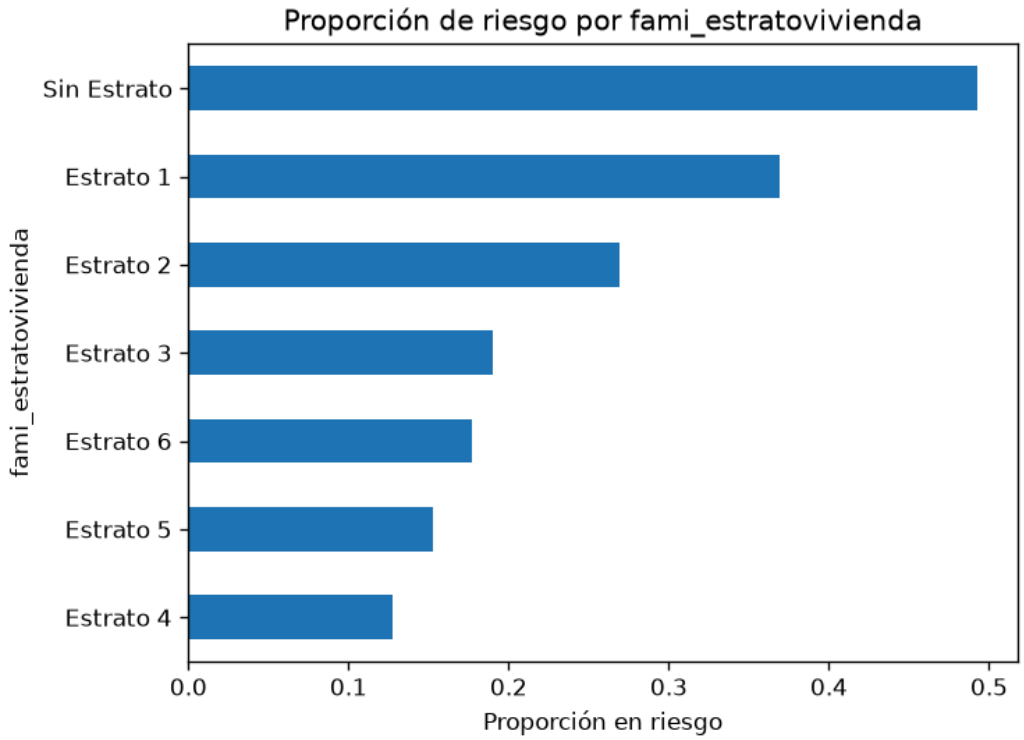
```
Tabla 'resultados' con 152584 filas en data/saber11.db
Tabla 'resultados' con 152584 filas en data/saber11.db
```

2. Exploración de datos

El análisis completo está en `notebooks/01_eda.ipynb`. De 152.584 filas, solo 76.253 son estudiantes únicos: las otras 76.331 son copias idénticas y se eliminan antes de separar los datos.



Distribución de punt_global, con el umbral P25 de 234



Proporción de riesgo por estrato

3. Preparación de datos

Separación 70/15/15 estratificada, con 0 duplicados de `estu_consecutivo`:

```
Umbral: 234.0
train 53377 0.2457
val   11438 0.2457
test  11438 0.2457
```

4. Entrenamiento y selección del modelo

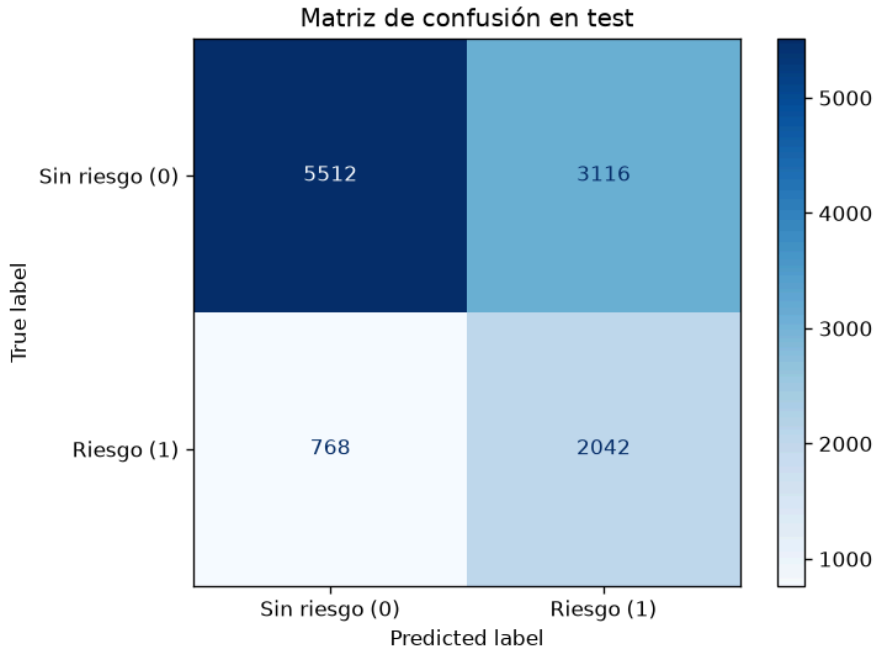
```
Métricas en validación (clase positiva: riesgo = 1)
Modelo         Accuracy  Precision     Recall         F1    ROC-AUC
baseline         0.7543     0.0000     0.0000     0.0000     0.5000
logreg           0.6554     0.3900     0.7139     0.5044     0.7486
tree             0.6276     0.3711     0.7431     0.4950     0.7360
Modelo seleccionado: logreg
```

5. Evaluación

Resultados en el conjunto de test:

```
Modelo seleccionado: logreg
| Modelo | Accuracy | Precision | Recall | F1 | ROC-AUC |
|---|---|---|---|---|---|
| baseline | 0.7543 | 0.0000 | 0.0000 | 0.0000 | 0.5000 |
| logreg | 0.6604 | 0.3959 | 0.7267 | 0.5126 | 0.7539 |
```

```
| tree | 0.6299 | 0.3736 | 0.7480 | 0.4983 | 0.7420 |
Matriz de confusión [[VN, FP], [FN, VP]]: [[5512, 3116], [768, 2042]]
```

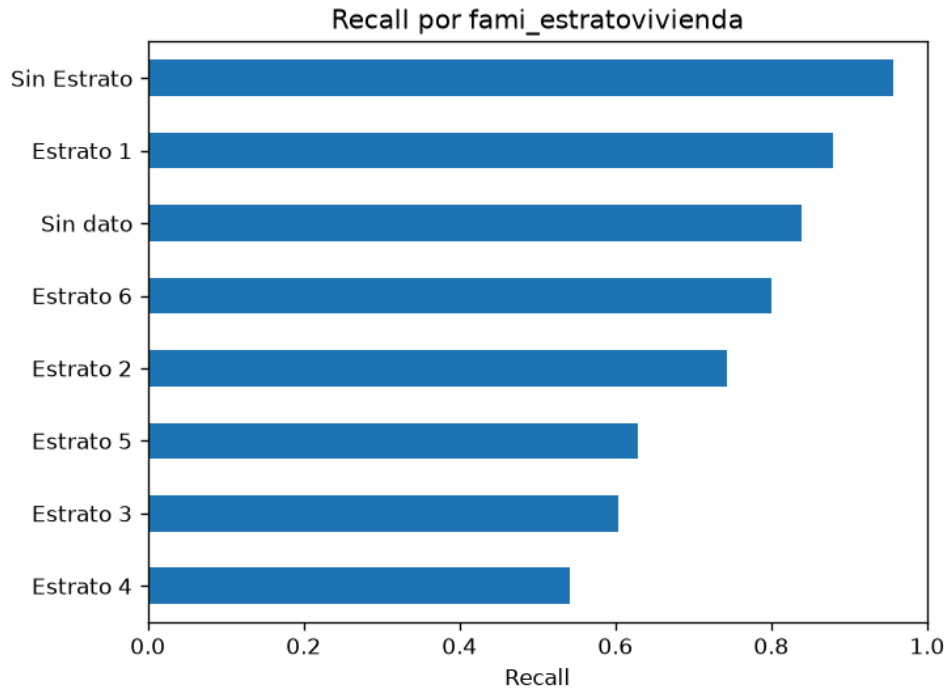


Matriz de confusión en test

6. Equidad

Brechas de recall y comparación con un modelo sin variables sensibles. El detalle por grupo está en `reports/equidad.md`.

```
       modelo     f1  brecha_estu_genero  brecha_fami_estratovivienda  brecha_cole_naturaleza  brecha_cole_area_ubicacion
     completo 0.5126              0.1359                       0.4141                  0.2393                      0.1380
sin_sensibles 0.5129              0.0158                       0.4433                  0.2487                      0.0421
estu_genero: brecha de recall 0.1359
fami_estratovivienda: brecha de recall 0.4141
cole_naturaleza: brecha de recall 0.2393
cole_area_ubicacion: brecha de recall 0.1380
```



Recall por estrato

7. Servicio

Respuestas reales de la API en ejecución:

```
GET /health -> {'status': 'ok', 'model': 'logreg'}
POST /predict -> 200 {'riesgo': 1, 'probabilidad': 0.5988269447741827}
POST /predict (categoría inválida) -> 422 ['body', 'fami_estratovivienda'] literal_error
POST /predict (sin edad) -> 422 ['body', 'edad'] missing
GET /metrics -> logreg
```

Medición de latencia con 500 solicitudes y 10 clientes concurrentes:

```
{
  "solicitudes": 500,
  "clientes": 10,
  "errores": 0,
  "p50_ms": 36.15,
  "p95_ms": 43.95,
  "max_ms": 73.15,
  "cumple_qa1": true
}
```



Documentación interactiva de la API en Swagger UI

Despliegue en la nube. La API está publicada en Render, plan gratuito, en https://saber11-api.onrender.com. Comprobaciones sobre el servicio publicado:

```
GET  /         -> 307, redirige a /docs (52,39 s: el servicio estaba dormido)
GET  /health   -> 200 {"status":"ok","model":"logreg"}
POST /predict  -> 200 {"riesgo":1,"probabilidad":0.5988269447741827}
POST /predict  -> 422 con un perfil incompleto
GET  /metrics  -> 200 con el reporte de test
```

Latencia en Render con 500 solicitudes y 10 clientes concurrentes. No cumple el umbral de 300 ms, que QA1 define para la ejecución local:


```
{
  "solicitudes": 500,
  "clientes": 10,
  "errores": 0,
  "p50_ms": 903.64,
  "p95_ms": 1273.44,
  "max_ms": 1794.12,
  "cumple_qa1": false
}
```

Latencia en Render con 100 solicitudes y 1 cliente. `GET /health` tarda unos 190 ms, así que casi todo el tiempo es red:


```
{
  "solicitudes": 100,
  "clientes": 1,
  "errores": 0,
  "p50_ms": 200.27,
  "p95_ms": 228.83,
  "max_ms": 377.37,
  "cumple_qa1": true
}
```




Swagger UI servido desde Render

8. Pruebas


```
tests/test_api.py::test_inicio_redirige_a_la_documentacion PASSED        [  3%]
tests/test_api.py::test_health_informa_el_modelo PASSED                  [  6%]
tests/test_api.py::test_predict_devuelve_riesgo_y_probabilidad PASSED    [  9%]
tests/test_api.py::test_predict_respeta_el_orden_de_las_variables PASSED [ 12%]
tests/test_api.py::test_umbral_de_decision PASSED                        [ 15%]
tests/test_api.py::test_predict_rechaza_valores_invalidos[fami_estratovivienda-Estrato 9] PASSED [ 18%]
tests/test_api.py::test_predict_rechaza_valores_invalidos[edad-8] PASSED [ 21%]
tests/test_api.py::test_predict_rechaza_valores_invalidos[estu_genero-None] PASSED [ 24%]
tests/test_api.py::test_predict_rechaza_perfil_incompleto PASSED         [ 27%]
tests/test_api.py::test_predict_rechaza_puntajes_e_identificadores PASSED [ 30%]
tests/test_api.py::test_metrics_devuelve_el_reporte PASSED               [ 33%]
tests/test_api.py::test_metrics_sin_reporte_responde_404 PASSED          [ 36%]
tests/test_api.py::test_esquema_coincide_con_las_variables_del_modelo PASSED [ 39%]
tests/test_api.py::test_carga_sin_artefactos_da_un_error_claro PASSED    [ 42%]
tests/test_api.py::test_la_api_no_depende_de_datos_ni_procesamiento PASSED [ 45%]
tests/test_data.py::test_features_sin_fuga PASSED                        [ 48%]
tests/test_data.py::test_preprocesador_rechaza_fuga PASSED               [ 51%]
tests/test_data.py::test_build_target_binario_y_umbral PASSED            [ 54%]
tests/test_data.py::test_split_estratificado_y_sin_repetidos PASSED      [ 57%]
tests/test_data.py::test_preprocesador_tolera_categoria_nueva PASSED     [ 60%]
```

```
tests/test_data.py::test_clean_quita_duplicados PASSED                   [ 63%]
tests/test_data.py::test_clean_calcula_edad_y_marca_fechas_invalidas PASSED [ 66%]
tests/test_data.py::test_load_config_lee_tildes_en_utf8 PASSED           [ 69%]
tests/test_data.py::test_load_config_sin_archivo_da_un_error_claro PASSED [ 72%]
tests/test_data.py::test_download_pagina_hasta_la_ultima_pagina PASSED   [ 75%]
tests/test_data.py::test_download_es_idempotente PASSED                  [ 78%]
tests/test_data.py::test_download_reintenta_si_una_pagina_falla PASSED   [ 81%]
tests/test_data.py::test_download_fallido_no_corrompe_el_csv_existente PASSED [ 84%]
tests/test_data.py::test_load_to_db_es_idempotente_y_conserva_el_texto PASSED [ 87%]
tests/test_model.py::test_calcular_metricas_devuelve_las_cinco_metricas PASSED [ 90%]
tests/test_model.py::test_metricas_por_grupo_calcula_recall_y_falsos_positivos PASSED [ 93%]
tests/test_model.py::test_metricas_por_grupo_conserva_los_valores_faltantes PASSED [ 96%]
tests/test_model.py::test_brecha_ignora_grupos_pequenos PASSED           [100%]
======================== 33 passed, 1 warning in 1.84s ========================
```